

UNIVERSIDADE SÃO JUDAS TADEU

ENGENHARIA

BRYAN LIRA JUNQUEIRA (825110147)

FELIPE CABRAL DE AQUINO (82510945)

GABRIEL MARTINS GOMES DE OLIVEIRA (825128943)

GUILHERME FERNANDES LIMA (82516937)

JOÃO CARLOS OLIVEIRA PASSOS (82510149)

**PROJETO PRÁTICO: COMITÊ DE CLASSIFICADORES (ENSEMBLE)
APLICADO AO MERCADO DE VIDEO GAMES**

SÃO PAULO

2026

**BRYAN LIRA JUNQUEIRA, FELIPE CABRAL DE AQUINO, GABRIEL MARTINS GOMES DE
OLIVEIRA, GUILHERME FERNANDES LIMA, JOÃO CARLOS OLIVEIRA PASSOS**

PROJETO PRÁTICO: COMITÊ DE CLASSIFICADORES (ENSEMBLE) APLICADO AO MERCADO DE VIDEO GAMES

Relatório técnico apresentado como requisito parcial para a avaliação A3 da disciplina de Inteligência Artificial do curso de Engenharia da Universidade São Judas Tadeu.

Professor Orientador: RODRIGO BOSSINI TAVARES MOREIRA

SÃO PAULO
2026

1. INTRODUÇÃO

O presente relatório detalha o desenvolvimento e a implementação de um sistema de Inteligência Artificial baseado em Aprendizado Supervisionado para a classificação de performance de jogos eletrônicos. O objetivo central é a construção de um comitê de classificadores (Ensemble Learning) capaz de inferir a percepção crítica de um título com base em variáveis mercadológicas e técnicas.

A abordagem utiliza a combinação de modelos distintos — K-Nearest Neighbors (KNN), Árvore de Decisão e Random Forest — para reduzir erros individuais e aumentar a robustez da predição final através de uma técnica de votação majoritária (Voting Classifier).

2. DESCRIÇÃO DA BASE DE DADOS

A base de dados selecionada, extraída da plataforma Kaggle, é a "Video Game Sales with Ratings". O dataset compreende registros históricos da indústria, incluindo variáveis fundamentais para a análise do setor. As features (variáveis independentes) selecionadas para o modelo foram:

- **Platform:** Console ou hardware onde o jogo foi lançado.
- **Genre:** Categoria temática do jogo.
- **Rating:** Classificação etária indicativa.
- **Global_Sales:** Volume total de vendas em escala global.

- **Ano de Lançamento:** Ano de lançamento do jogo.

3. DEFINIÇÃO DO PROBLEMA (TARGET)

O problema foi estruturado como uma tarefa de classificação multiclasse. A variável alvo (target) foi derivada da coluna *Critic_Score* (pontuação dos críticos), segmentada em três categorias discretas:

- **Bom:** Jogos com alta recepção crítica.
- **Médio:** Jogos com recepção mediana.
- **Ruim:** Jogos com baixa avaliação.

4. PRÉ-PROCESSAMENTO

O pipeline de dados foi desenvolvido em Python, utilizando as bibliotecas Pandas e Scikit-learn. As etapas de preparação incluíram:

1. **Limpeza de Dados:** Aplicação do método `dropna()` para eliminar registros com valores ausentes, garantindo que o cálculo de distância do KNN e a entropia das árvores não fossem comprometidos.
2. **Codificação de Variáveis Categóricas:** Utilização do `LabelEncoder` para converter variáveis nominais (como Plataforma e Gênero) em representações numéricas.
3. **Divisão dos Dados:** Separação da base em conjuntos de treinamento (70%) e teste (30%), garantindo a avaliação da capacidade de generalização do modelo em dados inéditos.

5. MODELAGEM E CONSTRUÇÃO DO COMITÊ

Foram implementados três classificadores de naturezas distintas para compor o comitê, maximizando a diversidade do ensemble:

- **K-Nearest Neighbors (KNN):** Algoritmo baseado em instâncias que classifica novos dados pela proximidade espacial aos vizinhos mais próximos.
- **Árvore de Decisão (Decision Tree):** Modelo que realiza sucessivas partições nos dados com base em critérios de pureza (Gini/Entropia).
- **Random Forest:** Método de Bagging que utiliza múltiplas árvores de decisão para mitigar o *overfitting* e aumentar a estabilidade.

O ****Comitê (Ensemble)**** foi construído através do `VotingClassifier` com o parâmetro `voting='hard'`, onde a classe vencedora é definida pela maioria simples dos votos entre os três modelos individuais.

6. RESULTADOS E MÉTRICAS

O desempenho dos modelos foi mensurado através da métrica de acurácia global. Os resultados obtidos foram:

Modelo	Acurácia
KNN	60.52%
Árvore de Decisão	55.25%
Random Forest	61.39%
Comitê (Ensemble)	61.51%

7. DISCUSSÃO E ANÁLISE CRÍTICA

O Comitê de Classificadores superou todos os modelos individuais, validando a premissa de que a combinação de estimadores independentes tende a convergir para resultados mais precisos. Contudo, a análise da Matriz de Confusão revelou um desafio estatístico: o modelo apresenta alta precisão na classe "Médio" (que possui maior representatividade na base), mas enfrenta dificuldades em distinguir as classes "Bom" e "Ruim".

Identificou-se que o uso do LabelEncoder pode ter introduzido um viés de ordem em variáveis nominais. Além disso, a natureza subjetiva das notas críticas indica que variáveis adicionais (como orçamento de marketing ou data de lançamento) poderiam melhorar o poder preditivo do sistema.

8. CONCLUSÃO

O projeto demonstrou com sucesso a aplicação de técnicas de Inteligência Artificial para resolver um problema complexo de classificação. O uso do ensemble provou ser a abordagem mais eficaz para o dataset utilizado. Para trabalhos futuros, recomenda-se o teste de técnicas de balanceamento de classes (como SMOTE) e a transição para o *soft voting* para refinar a tomada de decisão baseada em probabilidades.